给定联合分布(joint distribution) $p(x^{(i)},z^{(i)})=p(x^{(i)}|z^{(i)})p(z^{(i)})$ $\phi_j \ge 0, \ \sum_{j=1}^k \phi_j = 1$ zi服从多项式分布,是隐含类别标签 $z^{(i)} \sim \mathrm{Multinomial}(\phi)$ parameter ϕ_j gives $p(z^{(i)} = j)$

k表示zi能取到的个数

与几节课前讲过的高斯判别模型相比,把{yi=1},{yi=0}换成了{zi=j}

混合高斯模型(mixture of Gaussians)建模

 \mathbf{x}_{ii} 的条件分布是高斯分布 $\mathbf{x}^{(i)}|\mathbf{z}^{(i)}=ar{j}\sim\mathcal{N}(ar{\mu_{j}},\Sigma_{j})$

假设每个xi都是从{1,...,k}中随机选取zi来生成的,xi服从来自zi的k个高斯分布中的一个分布

zi是隐含随机变量(latent random variables)

模型的参数为 ϕ,μ,Σ

$$\ell(\phi, \mu, \Sigma) = \sum_{i=1}^{m} \log p(x^{(i)}; \phi, \mu, \Sigma)$$

$$= \sum_{i=1}^{m} \log \sum_{z^{(i)}=1}^{k} p(x^{(i)}|z^{(i)}; \mu, \Sigma) p(z^{(i)}; \phi).$$

如果我们用偏导数=0来求解各个参数,发现根本不可能以闭合形式(closed form) 来找到这些参数的最大似然估计

zi表示xi来自k个高斯分布的概率,假设zi已知

似然函数求解

 $\ell(\phi, \mu, \Sigma) = \sum_{i=1}^{m} \log p(x^{(i)}|z^{(i)}; \mu, \Sigma) + \log p(z^{(i)}; \phi)$ 则似然函数可以写成

$$\phi_{j} = \frac{1}{m} \sum_{i=1}^{m} 1\{z^{(i)} = j\},$$

$$\mu_{j} = \frac{\sum_{i=1}^{m} 1\{z^{(i)} = j\}x^{(i)}}{\sum_{i=1}^{m} 1\{z^{(i)} = j\}},$$

$$\Sigma_{j} = \frac{\sum_{i=1}^{m} 1\{z^{(i)} = j\}(x^{(i)} - \mu_{j})(x^{(i)} - \mu_{j})^{T}}{\sum_{i=1}^{m} 1\{z^{(i)} = j\}}.$$

也就是说,如果zi已知,那么这个最大似然估计几乎等同于高斯判别模型,只不过 这里zi扮演了高斯判别模型中分类标签的角色。

可是zi实际上是未知的,怎么办呢?由此引出了EM算法

是一个迭代算法,主要分为两步: E步、M步

E步去"猜测"zi的值,也就是计算zi的后验概率,M步基于猜测更新参数

Repeat until convergence: {

(E-step) For each i, j, set

$$w_j^{(i)} := p(z^{(i)} = j | x^{(i)}; \phi, \mu, \Sigma)$$

(M-step) Update the parameters:

$$\phi_j := \frac{1}{m} \sum_{i=1}^m w_j^{(i)},$$

$$\mu_j := \frac{\sum_{i=1}^m w_j^{(i)} x^{(i)}}{\sum_{i=1}^m w_j^{(i)}},$$

$$\Sigma_j := \frac{\sum_{i=1}^m w_j^{(i)} (x^{(i)} - \mu_j) (x^{(i)} - \mu_j)^T}{\sum_{i=1}^m w_j^{(i)}}$$

 $p(z^{(i)} = j | x^{(i)}; \phi, \mu, \Sigma) = \frac{p(x^{(i)} | z^{(i)} = j; \mu, \Sigma) p(z^{(i)} = j; \phi)}{\sum_{l=1}^{k} p(x^{(i)} | z^{(i)} = l; \mu, \Sigma) p(z^{(i)} = l; \phi)}$

与高斯判别模型相比,这里的均方差每个都不一样,而且这里的zi是多项式分布

与zi已知相比,这里的wj(i)代替了前面的1{zi=j},由简单的0/1变成了概率值

与k-means相比,这里的分配使用了"软"指定,k-means中给数据的所属簇进行了 强赋值,而这里给wj(i)进行了弱赋值

强是单次最佳猜测,例如从集合{0,1,...,k}中选出一个值

弱是指概率,从[0,1]区间内选定一个值

EM算法容易导致局部最优

Mixtures of Gaussians and the EM algorithm

期望最大值算法(Expectation-Maximization)

算法

些注意点