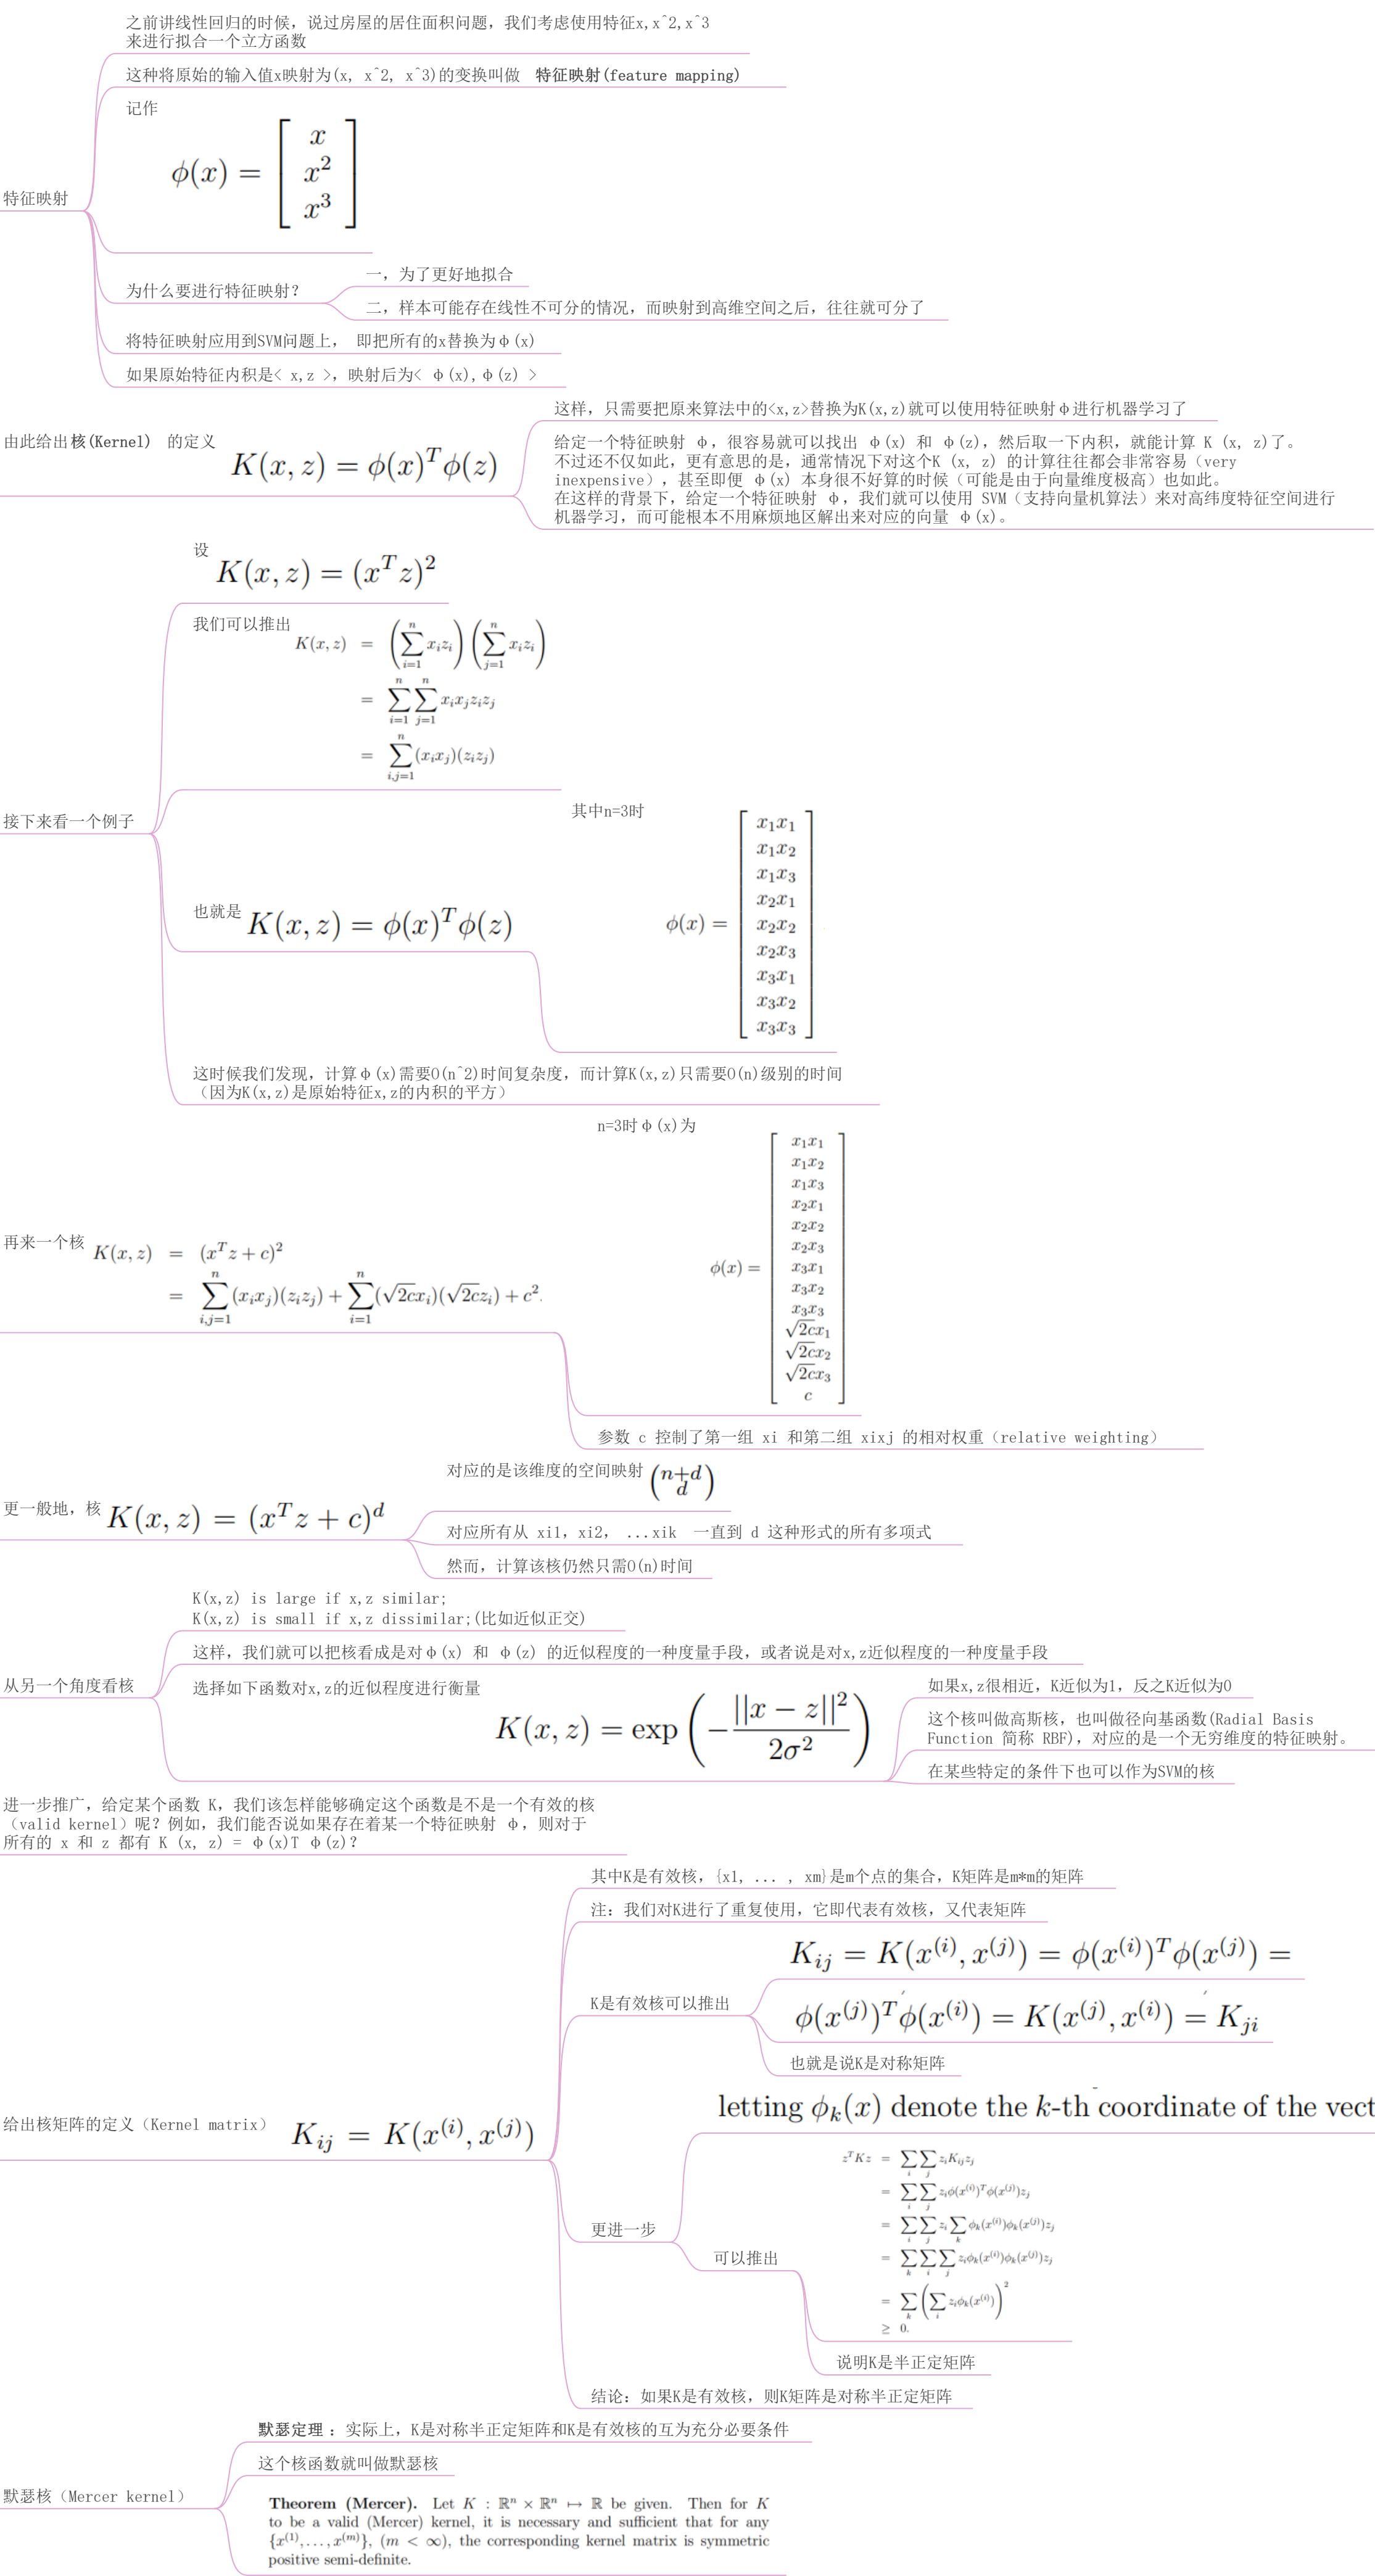


Support Vector Machine


Kernels



正则化和不可分情况处理

Regularization and the non-separable case

到目前为止的所有SVM内容，都是基于数据是线性可分的假设，但是这个假设有时候是不成立的，比如下图带有异常值，导致分界线出现偏移



要想让算法适用于非线性可分的数据集，那么就要降低算法对异常值的敏感度，也就是说要允许某些点违背约束条件 (函数间隔大于1)

方法：加入惩罚项。使用L1正则化来重构算法，得到下列新的模型，也叫作L1软间隔SVM模型

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i$$

s.t.  $y^{(i)}(w^T x^{(i)} + b) \geq 1 - \xi_i, i = 1, \dots, m$   
 $\xi_i \geq 0, i = 1, \dots, m.$

非负参数  $\xi_i$  叫做松弛变量，它允许某些样本点的函数间隔小于1，即允许某些点在最大间隔区间里面，或者某些点的函数间隔是负数。

后面的 $C \sum \xi_i$ 表示离群点越多，目标函数值越大，而我们要求的是最小的目标函数值。 $C$ 是离群点的权重，越大表示离群点对目标函数的影响越大，也就是越不希望看到离群点。

目标函数控制了离群点的数量和程度，使大部分样本仍符合条件

修改后的模型对应的拉格朗日函数

$$\mathcal{L}(w, b, \xi, \alpha, r) = \frac{1}{2} w^T w + C \sum_{i=1}^m \xi_i - \sum_{i=1}^m \alpha_i [y^{(i)}(w^T x^{(i)} + b) - 1 + \xi_i] - \sum_{i=1}^m r_i \xi_i$$

$\alpha_i$  和  $r_i$  都是拉格朗日乘数因子,  $>=0$

与往常一样，对 $w, b$ 求偏导，再带回，得到该问题的对偶式

$$\max_{\alpha} W(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m y^{(i)} y^{(j)} \alpha_i \alpha_j (x^{(i)} \cdot x^{(j)})$$

s.t.  $0 \leq \alpha_i \leq C, i = 1, \dots, m$   
 $\sum_{i=1}^m \alpha_i y^{(i)} = 0.$

还是和往常一样，可以把 $w$ 用 $\alpha_i$ 进行描述

往常详细解法见脑图SVM的Part 1的“最优边界分类器”中“求该函数的对偶形式”

神奇的一点，加入L1正则化后，对对偶问题的唯一改变只是约束从  $0 \leq \alpha_i$  变成了  $0 \leq \alpha_i \leq C$ 。这里对  $b$  的计算也受到了影响而有所变动

KKT对偶互补条件为

$$\begin{aligned} \alpha_i &= 0 \Rightarrow y^{(i)}(w^T x^{(i)} + b) \geq 1 \\ \alpha_i &= C \Rightarrow y^{(i)}(w^T x^{(i)} + b) \leq 1 \\ 0 < \alpha_i < C &\Rightarrow y^{(i)}(w^T x^{(i)} + b) = 1. \end{aligned}$$

在下一阶段 “The SMO algorithm” 中将求解该对偶式

The SMO algorithm

sequential minimal optimization (序列最小化优化算法)

先抛开具体问题，看这种算法

假如要解决无约束优化问题

$$\max_{\alpha} W(\alpha_1, \alpha_2, \dots, \alpha_m)$$

以前学过的优化算法有梯度下降法和牛顿法


坐标上升算法 Loop until convergence {

For  $i = 1, \dots, m$ , {  
 $\alpha_i := \arg \max_{\alpha_i} W(\alpha_1, \dots, \alpha_{i-1}, \alpha_i, \alpha_{i+1}, \dots, \alpha_m)$   
}

即每次通过优化 $W$ 来调整参数  $\alpha_i$

至于调整  $\alpha_i$  的顺序，我们这里按照变量排列顺序来调整，不过还有其他更复杂的顺序

坐标上升法的每一步中，移动的方向都是平行于某个坐标轴的 (parallel to one of the axes)，因为每次都只对一个变量进行了优化。以下是一个二维 (只有  $\alpha_1, \alpha_2$ ) 示意图



SVM对偶优化问题

$$\max_{\alpha} W(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m y^{(i)} y^{(j)} \alpha_i \alpha_j (x^{(i)} \cdot x^{(j)})$$

s.t.  $0 \leq \alpha_i \leq C, i = 1, \dots, m$   
 $\sum_{i=1}^m \alpha_i y^{(i)} = 0.$

由约束可得

$$\alpha_1 y^{(1)} = - \sum_{i=2}^m \alpha_i y^{(i)}.$$

进而可得

$$\alpha_1 = -y^{(1)} \sum_{i=2}^m \alpha_i y^{(i)}$$

这一步用到了

$$y^{(1)} \in \{-1, 1\}, \text{ and hence } (y^{(1)})^2 = 1$$

我们可以看出，按照坐标上升算法的思路每次优化一个参数是做不到的，因为有约束的限制，所以每次至少变动两个参数 (如果只变动一个参数， $\alpha_i$ 之和=0这个条件将不再成立)

Repeat till convergence {  
1: Select some pair  $\alpha_i, \alpha_j$  to update next (using a heuristic that tries to pick the two that will allow us to make the biggest progress towards the global maximum).  
2: Reoptimize  $W(\alpha)$  with respect to  $\alpha_i$  and  $\alpha_j$ , while holding all the other  $\alpha_k$ 's ( $k \neq i, j$ ) fixed.  
}

第一步用启发式方法选取  $\alpha_i, \alpha_j$ ;

第二步固定其他参数，确定 $W$ 取极值条件下的  $\alpha_i, \alpha_j$ 取值， (而  $\alpha_j$  是可以由  $\alpha_i$  进行表示的)

SMO之所以高效是因为固定其他参数后，对一个参数的优化过程很高效

下面讨论具体方法


根据约束得到

$$\alpha_1 y^{(1)} + \alpha_2 y^{(2)} = - \sum_{i=3}^m \alpha_i y^{(i)}$$

记为

$$\alpha_1 y^{(1)} + \alpha_2 y^{(2)} = \zeta$$

如图



$[0, C]$ 是第一个约束条件 在这里 $L=0$

需要注意的是，通过上面的约束条件，还能知道  $L \leq \alpha_2 \leq H$ ;

写出

$$\alpha_1 = (\zeta - \alpha_2 y^{(2)}) y^{(1)}$$

即

$$W(\alpha_1, \alpha_2, \dots, \alpha_m) = W((\zeta - \alpha_2 y^{(2)}) y^{(1)}, \alpha_2, \dots, \alpha_m)$$

把  $\alpha_3, \dots, \alpha_m$  当做常值，就能证明上面这个函数其实只是一个关于  $\alpha_2$  的二次函数。也就是说，可以写成

$$a \alpha_2^2 + b \alpha_2 + c$$

而对于这种二次函数求极值，就非常简单了

我们用如下符号表示最后的  $\alpha_2$ 取值  $\alpha_2^{new, unclipped}$

别忘了，如上图所示， $\alpha$  是有约束条件的，最后我们加上约束条件，得到

$$\alpha_2^{new} = \begin{cases} H & \text{if } \alpha_2^{new, unclipped} > H \\ \alpha_2^{new, unclipped} & \text{if } L \leq \alpha_2^{new, unclipped} \leq H \\ L & \text{if } \alpha_2^{new, unclipped} < L \end{cases}$$

得到了  $\alpha_2, \alpha_1$ 也就得到了